

浙江大学



本科实验报告

仪器软测量技术

课程名称： 仪器系统设计

姓名：

学院： 生物医学工程与仪器科学学院

专业： 生物医学工程

学号：

指导老师： 周泓

2025 年 6 月 7 日

浙江大学实验报告

专业： 生物医学工程
姓名：
学号：
日期： 2025 年 6 月 7 日
地点：

课程名称： 仪器系统设计 指导老师： 周泓 成绩：
实验名称： 仪器软测量技术 实验类型： 同组学生姓名：

1. 根据软测量技术原理，设计居家老人身体健康状态监测模型。

(1) 软测量技术应用背景

随着生产技术和生产过程的日益复杂，软测量技术作为一种重要的检测手段应运而生。在居家老人健康监测领域，同样面临着与工业过程类似的挑战：需要对与系统稳定及产品质量密切相关的重要过程变量进行实时检测和在线控制，但存在着无法用传统测量仪器直接检测的重要参数。

造成这一问题的主要原因包括：首先，由于技术条件限制，无法直接检测老人的整体健康状态，目前的检测技术和检测手段尚不完善；其次，在经济层面，先进的医疗检测设备成本过于昂贵，且某些检测方法造成的测量滞后无法满足实时监测的要求；再次，传统的健康监测设备通常只能感知单一的生理指标，需要对多个传感器的测量结果进行数据融合才能获得比较理想的健康评估结果。

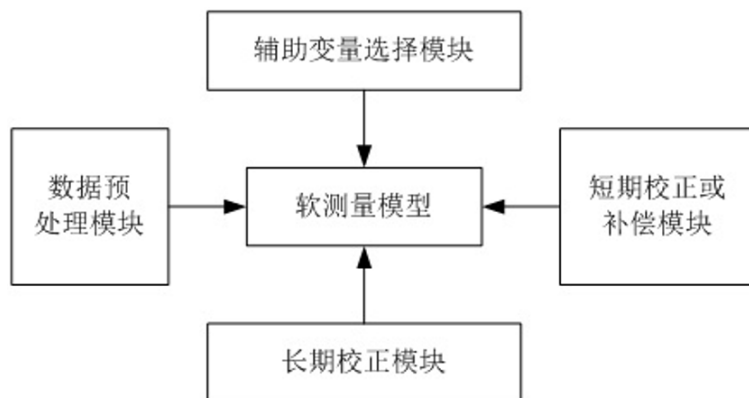


图 1: 软测量技术原理示意图

(2) 主导变量设定

基于软测量技术的推断控制思想，本模型的主导变量设定为难以直接测量的老人整体健康状态。这一主导变量涵盖整体健康水平、疾病风险评估、日常活动能力以及精神状态等多维度综合指标。这些变量由于其抽象性、复杂性和综合性特征，无法通过单一传感器或传统检测方法直接获取，正符合软测量技术所要解决的核心问题——通过易测的辅助变量来推断难测的主导变量。

(3) 辅助变量选择

按照软测量技术的核心思想，辅助变量选择是推断估计器构造的关键环节。辅助变量 θ 是指那些容易测量的二次变量，本模型将从四个维度构建可测信息集，用于建立从可测信息集 θ 到主导变量 y 的映射关系。

生理指标维度作为最直接的健康相关变量，通过可穿戴设备和智能家居设备采集心率、血压、体温、呼吸频率等基础生理参数，利用智能床垫监测睡眠时长和质量，通过智能手环记录步数、活动量，并使用家用医疗设备测量血糖、血氧饱和度。行为习惯维度反映老人的日常生活模式，包括通过智能餐具记录的饮食摄入量和规律性，通过智能药盒监测的用药依从性，以及通过智能门禁系统获取的出入家门时间和在家活动区域信息。环境信息维度通过各类传感器采集室内温度、湿度、光照强度和空气质量数据，这些环境因素直接影响老人的健康状态。主观反馈维度定期收集老人的情绪状态和身体不适感受，为模型提供重要的定性信息补充。

(4) 控制变量与干扰因素

表 1: 控制变量与干扰因素分类

变量类型	具体内容
控制变量 (u)	智能家居设备设置调节（温度、湿度、照明），健康提醒信息推送（用药、喝水、活动提醒），个性化健康建议（运动建议、饮食建议）
干扰因素 (d)	天气变化对心血管的影响，家庭环境变化（访客、噪音），突发事件（跌倒、急症），心理压力（孤独感）

(5) 软测量模型设计原理

模型设计严格遵循软测量技术的核心原理，即利用所有可以获得的信息求取主导变量的最佳估计值。根据软测量技术的四个主要方面要求，本模型构建包含辅助变量选择、数据处理、软测量模型建立和在线校正四个功能模块，其中软测量模型是整个系统的核心。

具体而言，本模型构造从可测信息集 θ 到主导变量 y 的映射关系，即 $y = f(\theta, u, d)$ ，其中可测信息集包括所有的可测主导变量 y 、辅助变量 θ 、控制变量 u 和可测扰动 d 。辅助变量选择模块负责识别与老人健康状态相关的多维度数据并进行初步筛选。数据预处理模块包含三个关键步骤：首先进行大量历史数据采集，随后执行数据清洗工作，包括异常值检测、缺失值处理和噪声滤波，最后对不同量纲的数据进行标度变换和非线性数据转换。

软测量模型建立模块采用基于数据驱动的建模方法，特别是人工神经网络方法，将预处理后的辅助变量作为网络输入，以老人健康状态为输出，通过网络学习建立非线性映射关系。考虑到医学机理知识，模型还可结合混合建模方法以提高准确性。在线校正模块分为短期校正和长期校正两个层面：短期校正根据老人最新的生理数据 and 行为模式及时调整模型参数，适应短期波动；长期校正则定期收集新的健康数据重新计算模型系数，适应身体的长期变化趋势。

(6) 系统架构流程图

基于软测量技术原理，居家老人身体健康状态监测模型的整体架构如图 2 所示。该流程图清晰展示了从多维度数据采集到健康状态评估输出的完整工作流程，体现了软测量技术的四个核心功能模块。

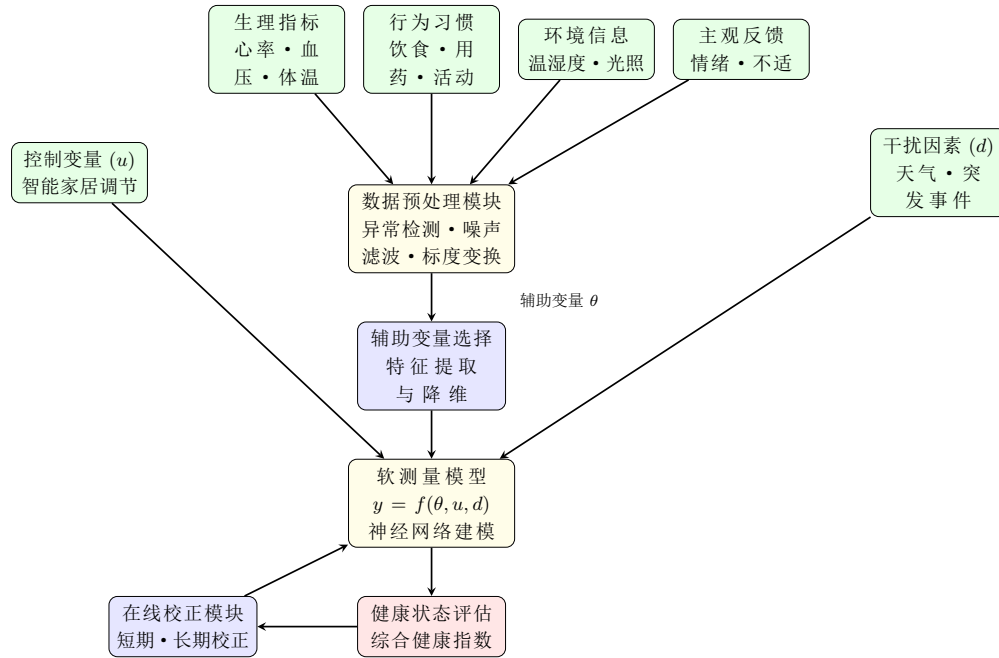


图 2: 居家老人身体健康状态监测系统架构流程图

2. 根据软测量技术原理，设计课堂质量评价模型。

(1) 模型应用背景与主导变量设定

课堂教学质量评价同样面临着软测量技术要解决的典型问题：需要对与教学系统稳定性和教学质量密切相关的重要过程变量进行实时检测和评价，但存在着无法用传统评价方法直接量化的重要参数。造成这一问题的主要原因包括：工艺条件限制使得无法直接检测课堂教学的综合质量；目前的教学评价技术和手段不够完善，尚不能完成复杂的教学质量实时评估任务；经济成本考虑使得难以配备先进的教学质量检测工具；传统的评价方法存在滞后性，无法满足实时性要求。

基于软测量技术的推断控制思想，本模型的主导变量设定为难以直接量化的课堂教学质量，这一综合性指标涵盖教学效果、学生参与度、教学满意度和知识掌握程度等多个维度。该主导变量具有典型的难测特征，正是软测量技术发挥作用的理想场景。

(2) 辅助变量系统设计

按照软测量技术构造从可测信息集 θ 到主导变量 y 映射关系的核心思想，本模型的辅助变量选择涵盖教师行为数据、学生行为数据、课堂环境数据和教学资源数据四个维度，形成完整的可测信息集。

教师行为数据作为教学质量的直接影响因素，通过多种技术手段采集，包括语音识别分析得到的语速、语调和音量变化，图像识别分析的板书或 PPT 使用情况，以及通过视频分析获取的课堂走动范围和身体姿态。学生行为数据反映学习参与程度和接受效果，包括课堂发言频率、互动次数、表情眼神分析、笔记记录情况，以及在线学习平台的活跃度和随堂练习的完成情况。课堂环境数据通过各类传感器获取温度、湿度、光照和噪音水平信息，这些环境因素直接影响教学效果。教学资源数据包括教学内容更新频率、教学资料下载量等客观指标。

(3) 模型架构设计

表 2: 课堂质量评价模型变量分类

变量类型	主要内容
主导变量 (y)	课堂教学质量（教学效果、学生参与度、教学满意度、知识掌握程度）
辅助变量 (θ)	教师行为（语速语调、板书使用、提问回应、走动姿态）、学生行为（发言互动、表情分析、笔记记录、平台活跃度）、环境数据（温湿度、光照、噪音）、主观反馈（学生问卷、教师反思、督导评价）
控制变量 (u)	教学方法调整、课堂活动设计、教学内容调整、教室环境调节
干扰因素 (d)	学生个体差异、突发事件、课程难度、外部环境噪音

(4) 软测量模型构建策略

本模型严格按照软测量技术的四个主要功能模块进行构建，以软测量模型为核心，建立从可测信息集到教学质量主导变量的映射关系 $y = f(\theta, u, d)$ 。软测量模型建立采用人工神经网络方法，该方法适合处理课堂质量评价中复杂的非线性关系。模型将各种辅助变量作为输入，以预设的课堂质量评价指标作为输出进行训练。

考虑到教育学的理论基础，模型可结合混合建模方法，通过教育学理论构建机理模型，再利用数据驱动模型进行补偿，从而充分体现软测量技术利用所有可以获得的信息求取主导变量最佳估计值的核心思想。在线校正模块按照软测量技术要求分为短期校正和长期校正：短期校正根据每节课的学生实时反馈和教师表现数据调整模型参数；长期校正定期收集学业成绩、毕业反馈和教学成果数据，重新训练模型以适应教学改革趋势。

(5) 课堂质量评价系统流程图

基于软测量技术原理设计的课堂质量评价模型架构如图 3 所示。该流程图详细展现了从多维度教学数据采集到课堂质量综合评价的完整技术路线，充分体现了软测量技术的四个核心功能模块在教育评价领域的具体应用。

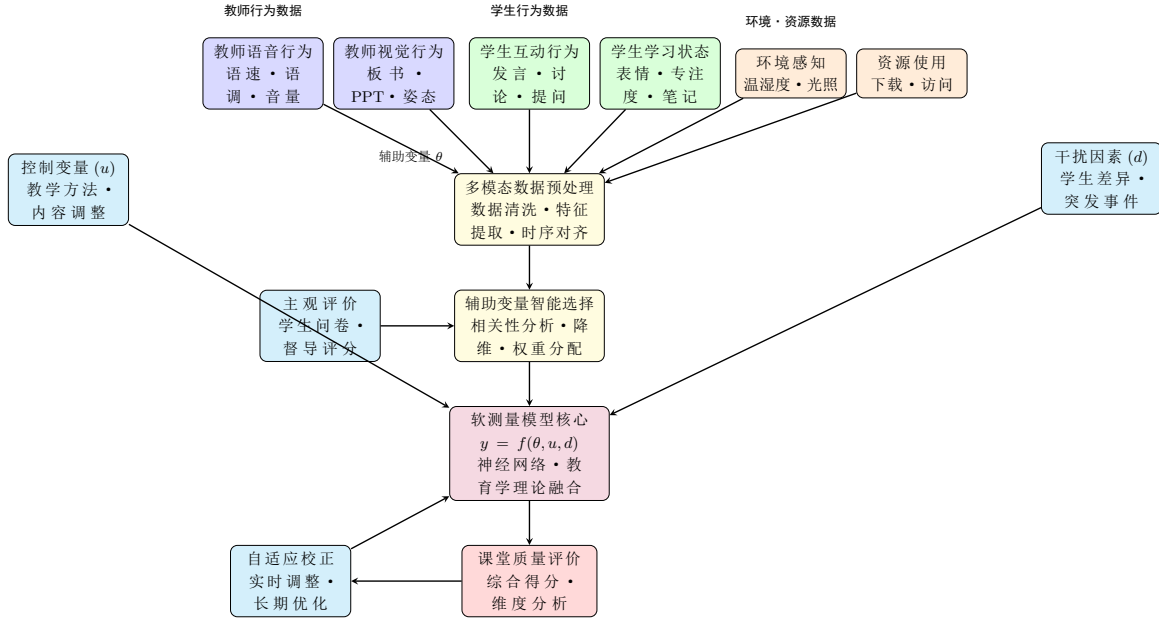


图 3: 基于软测量技术的课堂质量评价系统架构流程图

通过多模态数据融合实现对课堂教学质量这一难以直接量化指标的准确评估。系统集成教师行为、学生反应、环境条件等多维度信息，构建了完整的可测信息集，最终输出具有实际指导价值的课堂质量评价结果。模型的自适应校正机制确保了评价体系能够随着教学改革和技术发展不断优化。

3. 分析比较软测量模型的在线校正与离线校正的异同。

软测量模型建好后并不是一成不变的，它受到生产原料性质、产品品质需求、生产量甚至环境气候等多重因素的影响，操作点会发生相应的改变，偏离建立软测量模型时的工作点。为了解决这个问题，需要根据实际应用情况对模型进行适当的校正以适应工况的变化。软测量模型的在线校正分为短期校正和长期校正两种，通过模型的短期校正和长期校正，可以提高软测量模型的泛化能力，使之在运用环境发生变化后仍然保持较高的测量精度。

(1) 校正机制的共同特征

在线校正和离线校正作为软测量模型自适应调整的两种主要方式，在目标导向上完全一致，都致力于提高软测量模型的泛化能力，确保模型在运行环境发生变化后仍能保持较高的测量精度。两者均基于新样本数据的积累，依赖数据驱动的方式来更新或重新计算模型参数。最终目标都是确保软测量模型在实际应用中能够准确估计主导变量，解决操作点偏离原始建模工况的问题，提升整体模型性能和适应性。

(2) 短期校正与长期校正的技术特征

短期校正以某时刻软测量对象的真实值与模型的预测值之差为校正动力，及时校正模型的某些参数或常数项等。这种在线短期校正通常采用递推算法，能够在新数据到达时快速更新模型参数，实现实时响应，但需要考虑数据质量和异常值的影响。

表 3: 在线校正与离线校正对比分析

比较维度	在线校正	离线校正
时效性	实时或准实时进行，能够立即响应系统变化	定期进行，存在时间延迟，无法实时响应变化
数据处理方式	使用流式数据，逐个或小批量处理新数据点	使用批量数据，一次性处理大量历史数据
计算资源需求	计算复杂度相对较低，适合实时环境	计算复杂度较高，需要更多计算资源和时间
模型更新频率	连续或高频更新模型参数	周期性更新，更新频率较低
适应性	能快速适应系统动态变化，适合快变环境	适应性相对较慢，适合缓变环境
稳定性	可能因频繁更新导致模型不稳定	模型更新谨慎，稳定性较好
应用场景	实时控制系统、在线监测、快速响应场合	离线分析、模型优化、周期性维护

长期校正当模型运行一段时间积累了足够多的新样本数据后实施，即根据这些样本重新计算软测量模型的系数。长期校正可以离线进行也可以在线进行。离线校正实际上就是重新考虑建立软测量模型，可以利用完整的数据集进行全面的模型重建，采用更复杂的优化算法，但需要中断系统运行或在系统空闲时进行。在线长期校正可以由系统自动完成，但校正方法的使用受到现场装置的限制，通常采用递推算法。

(3) 综合应用策略

实际应用中，最佳策略往往是将短期校正和长期校正结合使用：短期校正处理日常的小幅变化和短期波动，通过及时调整模型参数保持模型的准确性；长期校正处理重大的系统性变化和长期趋势调整，通过重新估计模型系数来适应工况的根本性改变，形成多层次的自适应校正体系，确保软测量模型在各种工况变化下都能保持良好的性能。

4. 结合软测量技术实例，分析进行辅助变量精选——输入数据集降维的意义与方法。

(1) 辅助变量精选在软测量技术中的核心地位

辅助变量的选择对软测量非常重要，因为不可测的主变量需要由这些辅助变量推理出来。辅助变量的选择在软测量模型建立过程中同样起着重要的作用，包括变量的类型、变量的数目及测量点位置的选择三个方面。在软测量技术实施过程中，辅助变量精选即输入数据集降维具有核心意义。

首先，辅助变量精选直接影响软测量模型的准确性，因为模型精度很大程度上依赖于辅助变量的质量和相关性。选择合适的辅助变量确保模型能够有效推断主导变量，这是构建从可测信息集 θ 到主导变量 y 映射关系的基础。其次，降维有助于解决多重共线性问题，当辅助变量之间存在高度相关性时，可能导致模型不稳定和参数估计困难，影响 $y = f(\theta, u, d)$ 关系的准确建立。

从计算效率角度，降维能够减少模型的复杂度和计算负担，提高模型训练和推理速度，特别是在实时应用场景中尤为重要。同时，降维有助于避免维数灾难，在高维空间中，数据点变得稀疏，模型性能

可能显著下降。通过降维，可以在保留关键信息的同时简化数据结构，提升建模效率。

(2) 基于软测量技术实施流程的降维方法体系

表 4: 软测量技术中辅助变量精选方法及其技术特征

方法名称	方法特点与技术实现
辅助变量初选	根据工艺机理分析在可测变量集合中初步选择所有与被估计变量有关的原始辅助变量，这些变量中部分可能是相关变量。基于对被测对象的深刻认识，通过机理分析找出主导变量和辅助变量之间的关系。
现场数据采集与处理	采集被估计变量和原始辅助变量的历史数据，数量越多越好。现场数据必须经过显著误差检测和数据协调，保证数据的准确性。由于软测量一般为静态估计，应采集装置平稳运行时的数据，并注意纯滞后的影响。
主成分分析 (PCA) 精选	更为有效的方法是主元分析法，即利用现场的历史数据作统计分析计算，将原始辅助变量与被测量变量的关联度排序，实现变量精选。通过线性变换将数据投影到低维空间，保留最大方差信息。
机理分析精选	通过机理分析，可以在原始辅助变量中，找出相关的变量，选择响应灵敏、测量精度高的变量为最终的辅助变量。结合物理化学基本定律来表述过程的内部规律，识别具有因果关系的变量。

(3) 软测量建模方法选择策略

基于实际应用经验，软测量建模方法的选择应视具体的过程对象而定。如果有可能，在离线建模阶段，最好使用多种方法来建立软测量模型，然后从模型的精度、复杂程度、建模所用时间和可靠性等因素进行综合考虑。

基于机理分析的建模方法要求对被测对象的内部特性完全了解，从理论上说是最精确的模型。**基于数据驱动的建模方法**无须了解太多的过程知识，只需要获得足够多的数据即可建立模型，其中人工神经网络方法在解决高度非线性和严重不确定性系统控制方面具有巨大潜力。**混合建模方法**则结合了两方法的优势，简单机理模型提供的先验知识可以为数据驱动模型节省训练样本，同时数据驱动模型又能补偿简化机理模型的未建模特性。

在数据处理方面，必须经过除噪滤波、显著误差检测及数据校正等预处理步骤，该预处理模块在工程实施时所需的计算机资源较多，直接关系到软测量模型在实际应用中的可靠性和准确性。

(4) 主流降维方法的技术特征与应用效果

主成分分析 (PCA): PCA 是最经典的线性降维方法，通过寻找数据中方差最大的方向（主成分）来实现降维。其核心思想是将原始的高维数据投影到由主成分构成的低维子空间中，保留最大的数据方差信息。PCA 方法具有数学基础扎实、计算效率高、易于解释等优点，特别适用于数据中存在线性相关性的情况。

t-分布随机邻域嵌入 (t-SNE): t-SNE 是一种非线性降维方法，特别擅长保持数据的局部结构，能够在低维空间中保持高维数据点之间的相似性关系。其核心思想是构建高维空间中数据点的概率分布，然后在低维空间中寻找最相似的概率分布。t-SNE 在可视化高维数据的聚类结构方面表现优异，但计算复杂度较高，且结果具有一定的随机性。

均匀流形逼近和投影 (UMAP): UMAP 是较新的非线性降维方法，在保持数据全局结构和局部结构方面都有良好表现。相比 t-SNE，UMAP 具有更快的计算速度和更好的数据保持能力，特别适用于大规模数据集的降维可视化。

(5) 生物医学图像处理中的降维实践案例

在实际的生物医学数据处理中，维数灾难问题尤为突出。以我们在《生物医学图像处理》课程大作业中遇到的实际情况为例：MRI 图像数据集仅有 200 个样本，但却包含 1605 个特征，呈现出典型的“小样本、高维度”特征，这种数据分布正是软测量技术面临的典型挑战。

当数据的特征数量远远超过样本数量时，传统的距离度量失效，模型的预测能力会急剧下降，这种现象被称为“维数灾难”。在我们的实验中，1605 个特征对应 200 个样本，虽然不是极端情况，但有效的特征筛选仍然能显著提升效率和准确性。我们采用了多种降维方法来解决这一问题。

(6) 分层筛选策略的理论基础与实施细节

维数灾难现象：当数据的特征数量远远超过样本数量时，传统的距离度量失效，模型的预测能力会急剧下降。根据香农信息理论，一个好的特征应最大化与目标变量的互信息，同时最小化特征间的冗余信息。基于 Vapnik-Chervonenkis 理论，模型的泛化误差与其复杂度正相关，通过合理的特征选择，可以在保持预测精度的同时降低模型复杂度，从而有效控制过拟合的风险。

通过将《仪器系统设计》里基于软测量技术的核心思想迁移过去（加之我们小组开始的确实比较晚），我们在《生物医学图像处理》课程大作业中设计了分层渐进式的特征筛选策略，其理论基础主要建立在以下几个核心理论之上：

我们设计的五层渐进式特征筛选策略具体包括：

第一层：原始数据质量评估通过统计描述分析建立特征质量基线，包括方差分布、相关性结构、缺失比例等关键指标，为后续筛选提供量化的决策依据。

第二层：常数特征移除基于信息熵理论，方差接近零的特征其信息熵趋于零，对分类任务无贡献。设定方差阈值为 0.01，该参数选择基于经验值，能够有效移除真正的常数特征：

$$\text{Var}(X) = E[(X - \mu)^2] \approx 0$$

第三层：高相关特征消除当两个特征的皮尔逊相关系数绝对值超过 0.95 时，认为存在严重的多重共线性。皮尔逊相关系数 $\rho(X, Y)$ 的计算公式为：

$$\rho(X, Y) = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y}$$

其中， $\text{Cov}(X, Y)$ 是 X 和 Y 的协方差， σ_X 和 σ_Y 分别是 X 和 Y 的标准差。

第四层：单变量统计筛选运用 F 检验进行单变量统计筛选，评估每个独立特征与目标变量之间的统计关联强度。F 检验的核心思想是方差分解，将目标变量的总变异分解为组间方差和组内方差：

$$F = \frac{\text{组间方差}}{\text{组内方差}}$$

F 值越大，表示特征的判别能力越强。

第五层：集成学习特征重要性评估采用随机森林算法进行特征重要性评估，能够捕获特征之间的非线性交互作用和高阶关系。随机森林特征重要性的计算原理为：

$$\text{Importance}(X) = \sum p(t) \times \Delta I(t)$$

其中 $p(t)$ 是节点 t 的权重， $\Delta I(t)$ 是节点 t 使用特征 X 进行分裂时所获得的信息增益或基尼不纯度减少量。

(7) 降维效果评估与实际挑战

在我们的实验中，我们对 3D-ResNet 网络的每一层特征都进行了 t-SNE 降维分析，如图 4所示。遗憾的是，降维结果显示各层特征都没有呈现出明显的聚类模式，这表明特征空间中不同类别的数据点之间缺乏清晰的分界线，导致我们最终无法将这个二分类任务的准确率提升到 0.7 以上。

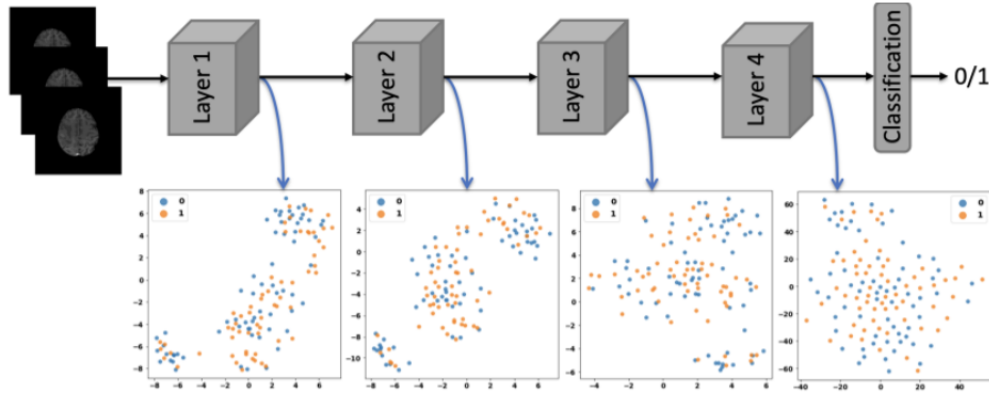


图 4: 3D-ResNet 各层特征的 t-SNE 降维可视化结果

当然，这并不意味着降维就是无用的，最终我们得出的结论是问题出在数据和标签的联系上。在实际应用中（软测量的辅助变量选择上），我们也可以采用降维的方法，帮助我们发现数据中的潜在结构，从而更好地达到如上论述的预期效果。